

BIG DATA

Introduction

Big data is... BIG

How much data in the world?

- 100-200 ZBs generated yearly
- Data grows faster than computing power


Facebook (2012)

- Storage increases 500TB/day (est. >8x today)
- 180PB/year

SKA telescope

- 3TB every second = 260PB/day
- To be compressed and reduced to 700PB/year

<https://explodingtopics.com/blog/data-generated-per-day>
<https://www.domo.com/data-never-sleeps#>
https://en.wikipedia.org/wiki/Square_Kilometre_Array#Data_challenges




Big data definitions

The term *big data* comes in two flavors

- Noun: referring to the dataset(s)
- Adjective: referring to the tools to operate on the dataset(s)

Big data definitions

When does data become *big*? Hard to say...




Big data definitions

Common definitions

- "Big data **exceeds the reach of commonly used hardware environments and software** tools to capture, manage, and process it with in a tolerable elapsed time for its user population."
Teradata Magazine article, 2011
- "Big data refers to data sets whose **size is beyond the ability of typical database software** tools to capture, store, manage and analyze."
The McKinsey Global Institute, 2012
- "Big data is data sets that are **so voluminous and complex that traditional data processing application software are inadequate** to deal with them."
Wikipedia

Big data definitions



http://www.ibmbigdatahub.com/sites/default/files/infographic_file/4-Vs-of-big-data.jpg

IBM

Big data definitions

Il modello delle 4 V descrive le caratteristiche fondamentali che definiscono i Big Data e che li rendono complessi da gestire rispetto ai dati tradizionali

Volume

In cosa consiste: La quantità massiccia di dati generata costantemente da utenti, sensori, app e transazioni. Perché è critico: Le dimensioni superano la capacità di archiviazione e calcolo dei singoli server o dei database relazionali tradizionali, richiedendo infrastrutture distribuite su più macchine

- Large quantity of data

Velocity

In cosa consiste: Il ritmo con cui i dati vengono creati, trasferiti ed elaborati. Perché è critico: In molti contesti, i dati perdono valore in fretta. Analizzarli in tempo reale o in streaming è fondamentale per prendere decisioni immediate.

- Refers to the speed of data production...
- ...and to the speed of consumption and analysis

Variety

In cosa consiste: La coesistenza di formati diversi di dati provenienti da sorgenti eterogenee.

- Structured, unstructured, multimedia


Veracity

In cosa consiste: Il grado di affidabilità, accuratezza e qualità delle informazioni raccolte. Perché è critico: I dati grezzi sono spesso incompleti, rumorosi, incoerenti o obsoleti. Senza un'adeguata fase di pulizia, validazione e tracciamento della provenienza, si rischia di derivare modelli errati o assumere decisioni fuorvianti

- Refers to the trustworthiness of data
- Potentially inconsistent, incomplete, ambiguous, obsolete, false, approximate

Big data definitions

How many V's?



Are getting out of hand

Big data definitions

When used as a noun, the boundary between *normal* and *big* data is vague

When used as an adjective, its meaning is more specific

- Big data architectures (e.g., the Lakehouse architecture)
- Big data tools (e.g., Apache Spark)
- Big data programming models (e.g., Map-Reduce)

Why the hype

We have always known that data is powerful
What has changed?

Why the hype

Le nuove fonti digitali hanno guidato una crescita rapida e sostenuta


New digital sources have driven sustained, rapid growth in data volume and diversity

- Opening new analytical opportunities



Nel contesto dei Big Data, la somma di una quantità enorme di informazioni o comportamenti individualmente insignificanti genera un valore complessivo superiore a quello dei pochi dati "popolari" o generici.

Why the hype



Una singola informazione di nicchia o un singolo comportamento utente può sembrare insignificante se preso da solo. Quando però l'architettura dei Big Data consente di raccogliere, memorizzare ed elaborare l'insieme di tutti questi piccoli eventi "insignificanti", si genera la quota di valore analitico più grande, consentendo una personalizzazione profonda e l'individuazione di pattern altrimenti invisibili.

"We sold more items today that didn't sell at all yesterday than we sold today of all the items that did sell yesterday" - Amazon employee

The most value does not come from the small set of highly popular items, but from the long list of niche items

- ^{Messi insieme} Put together, the *individually-insignificant* data is actually the most valuable
- Contrasts the 80-20 Pareto rule

Why the hype

In some cases, bigger = smarter

Google Translate (very much simplified)

- You collect good-quality snippets of translations
- You match sentences to snippets / train a neural network

Why does it work?

- There are tons of snippets on the Web
- The accuracy improves as the training set grows



Why the hype


In some cases, bigger = smarter

AI and LLMs


il legame diretto tra la dimensione/qualità dei dati e l'efficacia dei modelli di IA e LLM.

- Big Data play a fundamental role in the AI lifecycle
- Foundation models process web-scale multimodal corpora, making data selection, deduplication, governance, lineage and efficient computations of critical concern

L'IA dipende criticamente dalla fase di gestione dei dati (Data Collection & Management). I dati rappresentano il "carburante" con cui il modello impara.



Some success stories



Some success stories

Crime Prevention in Los Angeles

- <https://datafloq.com/read/los-angeles-police-department-predicts-fights-crim/279>

Diagnosis and treatment of genetic diseases

- http://www.pmlive.com/pmhub/healthcare_digital_communications/blue_latitude/white_papers_and_resources/big_data_privacy_and_the_rise_of_genomic_testing

Investments in the financial sector

- <https://mapr.com/blog/how-financial-services-industry-is-winning-with-big-data/>

Generation of personalized advertising

- <https://www.smartdatacollective.com/big-data-improving-personalized-marketing-campaigns/>

Astronomical discoveries

- <https://www.smithsonianmag.com/science-nature/next-big-discovery-astronomy-scientists-probably-found-it-years-ago-they-dont-know-it-yet-180969073/>

Injury prevention of football players

- https://www.repubblica.it/sport/vari/2018/09/12/news/big_data_calcio_ricerca_cnr_paolo_cintia-206220338/

Many use cases

Today's Challenge	New Data	What's Possible
Healthcare: Expensive office visits	Remote patient monitoring	Preventive care, reduced hospitalization
Manufacturing: In-person support	Product sensors	Automated diagnosis, support
Location-Based Services	Real time location data	Geo-advertising, traffic, local search
Public Sector: Standardized services	Citizen surveys	Tailored services, cost reductions
Retail: One size fits all marketing	Social media	Sentiment analysis, segmentation

Is there a limit?

Privacy can become an issue, and ethical questions must be asked


- AOL search data leak (NYT, 8/9/2006)
- Anonymous Netflix vs IMDB database (Wired, 12/13/2007)
- Why Johnny Can't Browse The Internet In Peace (Forbes, 8/1/2012)
- [How Companies Learn Your Secrets](#) (NYT, 16/2/2012)

Big Data lifecycle

Big Data lifecycle


Big Data is not just about storage or analysis

Data follows a typical **lifecycle**, with each step posing its own challenges



"Challenges and Opportunities with Big Data". A community white paper developed by leading researchers across the United States, 2012

Big Data lifecycle



La fase di Acquisizione definisce quali dati raccogliere e come catturarli.

①

Acquisition

• Selection

- Big data doesn't have to be too big
- Understand which data is actually valuable

Un errore comune è pensare che l'obiettivo sia accumulare indiscriminatamente qualsiasi dato disponibile. In realtà, la prima sfida è strategica: bisogna capire quali dati sono realmente utili per il problema o il modello che si desidera sviluppare. Raccogliere dati irrilevanti aumenta solo i costi di archiviazione e la complessità di gestione senza aggiungere valore.

• Filtering & compression

- Raw data is often too voluminous to store it all

In scenari ad alta velocità (es. sensori IoT), i dati in arrivo in tempo reale possono saturare i sistemi. La fase di acquisizione prevede quindi:

- Filtraggio: Scarto immediato dei dati palesemente inutili, duplicati o affetti da rumore prima ancora che vengano salvati.
- Compressione: Riduzione dell'impronta di memoria per ottimizzare i costi e i tempi di trasferimento su rete.

• Collect metadata


Metadati: Sono i "dati che descrivono altri dati". Raccogliere metadati è essenziale per poter indicizzare, organizzare, misurare e controllare l'enorme massa di dati salvati.

- Metadata is fundamental to understand, measure, and control the data
- Provenance tracing enables trustworthiness, reproducibility, debugging, etc.

Tracciabilità dell'origine: registrare da dove proviene ciascun dato e quali passaggi ha attraversato.

- Trustworthiness (Affidabilità): Garantisce che il dato provenga da una fonte sicura e non sia stato alterato malevolmente.
- Reproducibility (Riproducibilità): Consente di riprodurre gli stessi esperimenti o analisi ottenendo gli stessi risultati.
- Debugging: Rende possibile risalire all'origine del problema se si scopre un errore nell'output delle analisi.

Big Data lifecycle



La fase di Estrazione ha lo scopo di prendere i dati grezzi raccolti nella fase di acquisizione, filtrarli, pulirli e convertirli in un formato strutturato e utilizzabile per l'analisi.

②

Extraction

- **Transformation, normalization**

Estrarre le informazioni necessarie

- ~~Pull out the required information~~ and express it in a structured form suitable for analysis

- Often application dependent

Le tecniche di estrazione variano completamente in base al dominio applicativo

- Different features are extracted from an image of an MRI and one of the Solar System

- **Cleaning, error handling**

I dati di reale utilizzo presentano spesso problemi di qualità che, se non corretti, corromperebbero i risultati delle analisi.

- Recognize inaccurate data (e.g., faulty sensors)

Informazioni errate dovute a malfunzionamenti dell'hardware o dei sistemi di rilevamento


- Recognize unreliable data (e.g., biased opinions)

Informazioni soggettive, manipolate o distorte da pregiudizi/bias

- Recognize obsolete data

Informazioni che erano valide in passato ma non lo sono più nel contesto attuale

Big Data lifecycle



- Standardization (Standardizzazione): Uniformare i formati dei dati.
- Entity Resolution (Risoluzione delle entità): Identificare quando due record in database differenti si riferiscono alla stessa entità reale.
- Conflict Management (Gestione dei conflitti): Risolvere le contraddizioni di significato (semantica) o di forma (struttura) tra tabelle e documenti provenienti da fonti diverse.

③

Integration

La fase di Integrazione ha lo scopo di unire dati provenienti da sorgenti diverse, eterogenee e indipendenti per permetterne l'analisi congiunta.

- Discover the relationships between datasets Individuare i collegamenti impliciti tra sorgenti distinti
- Standardization, entity resolution, conflict management
 - Resolve heterogeneities and conflicts in data structure and semantics
 - There is a tendency to adopt *pay-as-you-go* techniques
 - Alternative to the structured integration approach (too heavy)
 - Semi-automatic integration based on mappings
 - Iterative refinement by the user as new mappings are discovered
 - Understand the trade-off of different modeling strategies

Integrazione incrementale
Pay-as-you-go

Integrazione strutturata, totale ed anticipata

Gli algoritmi analizzano i file e suggeriscono automaticamente le possibili corrispondenze tra dataset diversi. Ad esempio, il sistema riconosce autonomamente che la colonna `Codice_Fiscale` del file A ha lo stesso significato della colonna `TAX_ID` del file B.

L'analista di dati valida e corregge i suggerimenti dell'algoritmo man mano che lavora sui dati. L'integrazione non avviene tutta insieme al giorno zero, ma migliora gradualmente e in modo iterativo ogni volta che si scoprono nuove associazioni tra le tabelle (new mappings).

Si salvano tutti i dati grezzi e si integrano solo le porzioni di dato che servono per l'analisi che si desidera fare in quel preciso momento. Si "paga" il costo dell'integrazione (in termini di tempo, calcolo e lavoro umano) solo quando e dove serve effettivamente.

Significa comprendere i compromessi tra le scelte architetturali:

- Integrazione totale anticipata: Costosa e lenta, ma garantisce massima coerenza dei dati.
- Integrazione Pay-as-you-go: Veloce ed economica all'inizio, ma richiede che gli analisti gestiscano parte della pulizia/integrazione durante l'analisi stessa.

Nei vecchi Data Warehouse, prima di poter fare qualsiasi analisi dovevi progettare un unico schema rigido, rimodellare tutti i database dell'azienda e risolvere preventivamente ogni singolo conflitto di formato. Nei Big Data questo approccio è "troppo pesante": le fonti cambiano continuamente, la quantità di dati è enorme e si rischierebbe di passare anni a strutturare dati che magari non verranno mai usati.

Big Data lifecycle

La fase di Analisi ha lo scopo di elaborare i dati (già acquisiti, estratti e integrati) per estrarre valore pratico e generare conoscenza aziendale.

④

Analysis

• Exploration

- Approach the data with an explorative approach
- Gain a full understanding through real-time interactions

esplora i dati senza assumere ipotesi rigide a priori, così da acquisire una comprensione globale della loro struttura e distribuzione.

• Analytics Analisi Avanzata

- Understand which approach works better to solve a business problem
 - Traditional BI and OLAP analysis
 - Data mining, machine learning, AI
- Develop scalable and fast performing algorithms


- Business Intelligence e OLAP tradizionali sono indicati per aggregare dati storici, creare report e analizzare gli indicatori da diverse dimensioni analitiche.
- Data Mining, Machine Learning e AI sono necessari per individuare relazioni nascoste, effettuare classificazioni automatizzate o costruire modelli predittivi.

Dato il volume dei Big Data, i classici algoritmi devono essere riprogettati per essere eseguiti in modo distribuito e parallelo, garantendo elevati livelli di prestazioni e tempi di risposta contenuti.

• Delivery Restituzione e Comunicazione

- Find the best way to model and represent the results
- Enable non-expert user to further explore and interact with the results

- Rappresentazione dei risultati: Trovare la modalità di modellazione e rappresentazione visiva dei dati più chiara ed efficace per presentare l'output delle analisi.
- Accessibilità per utenti non tecnici: Rendere le informazioni fruibili anche ai decisori aziendali o manager che non hanno competenze tecniche di data science, mettendoli in condizione di esplorare autonomamente dashboard interattive per assumere decisioni strategiche.



- BI e OLAP (Comprendere il passato): Forniscono visibilità sullo stato di salute dell'azienda, consolidano i KPI e consentono di esplorare i dati storici aggregandoli lungo diverse dimensioni. La decisione finale rimane interamente in mano all'utente umano.
- Data Mining, ML e AI (Anticipare il futuro): Identificano correlazioni e relazioni non evidenti, costruiscono modelli probabilistici per prevedere scenari futuri e suggeriscono o eseguono azioni automatiche.
Checklist di verifica per l'applicazione nel progetto:
> Identificare l'obiettivo dell'analisi: Utilizzare BI/OLAP se l'output richiesto è un report, una dashboard interattiva o un confronto storico. Scegliere ML/AI se l'obiettivo è la stima di un valore futuro, una classificazione automatica o la prevenzione di un evento.
> Valutare l'infrastruttura sottostante: Modellare schemi ad albero/stella su Data Warehouse per la BI; predisporre pipeline su Data Lake per addestrare algoritmi ML su dati grezzi, multimodali o flussi in streaming.
> Pianificare l'integrazione operativa: Progettare la restituzione tramite interfaccia grafica per utenti business in caso di BI; distribuire modelli containerizzati e serviti via API se la predizione deve alimentare direttamente i sistemi applicativi in tempo reale.

Big Data lifecycle - Analysis scenarios

Three main scenarios: I tre scenari di analisi dei Big Data si differenziano in base alla latenza di elaborazione, alla quantità di dati processata per singola operazione e alla modalità di accesso alla memoria (I/O)

A

Analytics (batch)

Elaborazione Batch / a Lotti: L'analisi viene eseguita su enormi volumi di dati già memorizzati nei sistemi d'archivio (es. Data Lake o Data Warehouse). Può prevedere calcoli da semplici a molto complessi.

Il calcolo richiede da diversi minuti fino a varie ore.

- Simple/complex computations over large amounts of stored data (minutes, hours) (estrarre report strategici)
- Collect, transform, and model data to discover useful information and support decision-making

Tipo di I/O

- Append-only I/O (i dati storici vengono solo letti; i risultati dell'elaborazione vengono scritti in aggiunta o in nuovi file, senza modificare o sovrascrivere i dati grezzi originali).

B

Interactive (near-real-time)

Elaborazione Interattiva: Calcoli semplici eseguiti su porzioni di dati memorizzati (che possono spaziare da piccoli a grandi volumi) a seguito di un'interazione utente.

Il calcolo richiede da pochissimi millisecondi ad alcuni secondi.

- Simple computations over small/large amounts of stored data (milliseconds, seconds)
- Process data to quickly affect the environment (e-commerce, search engines, booking, ...) condizionare ed evolvere l'ambiente applicativo in tempo reale.
- Read/write I/O (lettura e scrittura attiva sul database per consultare e aggiornare lo stato delle transazioni o delle risorse).

C

Streaming (near-real-time)

Elaborazione in Flusso: Calcoli semplici eseguiti al volo (on the fly) su piccolissime quantità di dati che arrivano continuamente e in tempo reale.

(Il calcolo richiede Millisecondi o frazioni di secondo)

- Simple computations over small amounts of continuously incoming data
- Monitor and analyze data on the fly via time windows (tramite finestre temporali) per intercettare anomalie o inviare notifiche istantanee.
- Stream I/O (il dato fluisce direttamente in memoria attraverso il motore di streaming e viene analizzato mentre transita, prima o indipendentemente dall'archiviazione finale su disco).

Esempi: Generazione dei bilanci e dei report di vendita mensili, ricalcolo periodico dei profili utente, addestramento notturno di modelli di Machine Learning.


Esempi: Ricerca di prodotti o filtri su un e-commerce, interrogazione di un motore di ricerca, prenotazione di voli o hotel su piattaforme online.

Esempi: Rilevamento automatico di frodi su carte di credito, monitoraggio in tempo reale dei sensori IoT industriali o analisi dei log di rete per prevenire attacchi informatici.

Big Data lifecycle - Analysis goals

illustra come il valore aziendale generato (asse Y) aumenti progressivamente all'aumentare della difficoltà tecnica e metodologica (asse X) attraverso quattro livelli di analisi sui dati

I quattro livelli di analisi seguono una dipendenza propedeutica (necessaria per svolgere la seguente) e sequenziale ("una dopo l'altra"): ciascun livello sfrutta l'output informativo del livello sottostante come prerequisito per generare un valore superiore.




L'evoluzione analitica richiede di passare dal semplice monitoraggio del passato alla prescrizione automatizzata delle azioni future, muovendosi verso soluzioni a maggior valore strategico ed elevata complessità algoritmica.

Big Data lifecycle - Analysis goals

- I** **Descriptive analytics** Analisi Descrittiva
Fornisce informazioni sul passato
▪ Give insights into the past (*what happened*) se qualcosa va bene o male
▪ Simply signal that something is wrong or right
- Scopo: Fornire informazioni sul passato identificando cosa è successo.
- Funzione: Funziona come un sistema di monitoraggio base o un allarme rapido, segnalando semplicemente se un indicatore o una situazione è corretta o errata (es. rilevare un calo delle transazioni nelle ultime 2 ore).
- II** **Diagnostic analytics** Analisi Diagnostica
Fornisce approfondimenti dettagliati su
▪ Give in-depth insights into a particular problem Confronta i dati storici con altri dati
▪ Measure historical data against other data to answer the question of *why something happened*
- Scopo: Analizzare in profondità una problematica specifica per comprendere perché è successo.
- Funzione: Confronta e incrocia i dati storici con altre fonti informative per isolare le cause radice dell'evento rilevato dalla fase descrittiva (es. correlando il calo delle transazioni con un malfunzionamento del gateway di pagamento).
- III** **Predictive analytics** Analisi Predittiva
Utilizza i risultati delle
▪ Use the findings of descriptive and diagnostic analytics to predict *what is likely to happen* per prevedere
- Scopo: Stimare gli eventi futuri determinando cosa è probabile che accada.
- Funzione: Utilizza gli output delle fasi descrittiva e diagnostica come features per addestrare modelli statistici e di Machine Learning, calcolando la probabilità di accadimento di uno scenario futuro.
- IV** **Prescriptive analytics** Analisi Prescrittiva
intraprendere
▪ Prescribe *what action to take* to eliminate a future problem Sfrutta appieno
▪ Take full advantage of a promising trend
- Scopo: Determinare l'azione operativa ottimale indicando cosa fare.
- Funzione: Va oltre la stima futura traducendo le previsioni in raccomandazioni o azioni automatizzate: prescrive l'intervento esatto da eseguire per prevenire un disservizio o per sfruttare appieno un'opportunità di mercato favorevole.

Big Data lifecycle



La fase di Interpretazione ha lo scopo di trasformare i pattern e i risultati emersi dall'analisi in conoscenza solida e affidabile per guidare le decisioni.

5

Interpretation

- **Do not rush to conclusions**

- It is not *that* difficult to collect big data
- It is hard to extract valuable knowledge

La vera sfida risiede nell'esaminare questo enorme volume di dati per estrarre informazioni che abbiano un reale impatto pratico e strategico.

- **Fundamentals**

Per non cadere in errate interpretazioni dei dati, occorrono:

- Domain knowledge, data provenance

- **Always verify the results**

- Account for the made assumptions
- Use small artificial samples to verify our expectations

Esplicitare le ipotesi: Ogni modello analitico si basa su semplificazioni della realtà; è fondamentale documentare queste ipotesi per conoscere i limiti di validità delle conclusioni.

- **Extract knowledge**


- Identify interesting correlations or hidden patterns

L'obiettivo finale è far emergere strutture non evidenti nei dati (pattern).


Do not mistake correlation for causation

Prima di applicare algoritmi complessi a enormi volumi di dati, occorre testare le proprie ipotesi su piccoli dataset artificiali dei quali si conosce già il risultato atteso, così da verificare la correttezza della logica analitica.

Distinguere la correlazione dalla causa: Il fatto che due variabili crescano o decrescano insieme (es. il consumo energetico e il consumo di notizie ambientali mostrato nel grafico della slide) indica una correlazione statistica, non che un evento provochi l'altro. Confondere la correlazione con un legame di causa-effetto porta a decisioni strategiche fallimentari.



Big Data lifecycle



La fase di Decisione ha lo scopo di tradurre la conoscenza estratta dai dati in un'azione strategica concreta.

6

Decision

- The decision-making process requires strong managerial skills

- Evolve the business strategy based on the acquired knowledge
- Verify the impact of your decision on the newly acquire data
- Provide feedback for a continuous improvement of the process

L'architettura tecnologica e i modelli analitici (per quanto complessi o basati sull'IA) non prendono decisioni strategiche autonomamente: forniscono raccomandazioni, scenari e previsioni. La responsabilità di assumere rischi, definire la visione e valutare il contesto di mercato rimane in mano alla leadership manageriale.

L'obiettivo dei Big Data è guidare il cambiamento. La conoscenza estratta dalle fasi precedenti deve essere utilizzata per adattare le strategie operative o di business.

I risultati misurati sul campo vengono riammessi nel sistema come feedback. Questo permette di affinare e calibrare continuamente l'intero ciclo: Aggiustando quali dati acquisire nella fase di Acquisition. Perfezionando le regole di pulizia ed estrazione nella fase di Extraction. Ricalibrando i modelli di Machine Learning nella fase di Analysis.

Il ciclo di vita dei Big Data è un circuito chiuso (feedback loop). Quando una decisione viene attuata nel mondo reale, genera immediatamente nuovi flussi di dati (nuove vendite, nuovi ticket, nuovi log). È fondamentale monitorare questi nuovi dati per verificare se la decisione ha prodotto l'impatto desiderato o se ha introdotto effetti collaterali inattesi.

The beginning of the Big Data era

Technical challenges

- Data cannot fit a single machine
 - You need many computers that work together to reach a common goal
- Parallelization challenges
 - How do we organize and assign work units to workers?
 - How do we handle communications between work units of the same application?
 - And between applications/services?
- Fault-tolerance challenges
 - How to avoid data loss if disks/machines break?
 - What do we do if machines break (or network goes down) mid-processing?

The beginning of the Big Data era

The solution

- Hide system-level details from the developers
 - No more race conditions, lock contention, etc.
 - No need to become hardcore techies
- Separate the *what* from the *how*
 - Developer specifies the computation that needs to be performed
 - Execution framework (“runtime”) handles the actual execution
 - The cluster/datacenter *is* the computer

The beginning of the Big Data era

2003: Google publishes about its cluster architecture & DFS (GFS)

2004: Google publishes about its MapReduce programming model on top of GFS

- Written in C++
- Closed-source, Python and Java APIs available to Google programmers only

2006: Apache & Yahoo! → Hadoop & HDFS (Doug Cutting and Mike Cafarella)

- Java implementations of Google MapReduce and GFS with a diverse set of APIs available to public evolved from Apache Lucene/Nutch open-source web search engine

2008: becomes an independent Apache project

- Yahoo! uses Hadoop in production


2012: Hadoop 1.0 is released

- Hadoop 2.0 follows in 2013, while Hadoop 3.0 is released in 2017

Today: used as a general-purpose storage and analysis platform for big data

- Widely used for data storage
- Adopted by organizations who need/want to rely on open-source software

MACHINE LEARNING, ARTIFICIAL INTELLIGENCE, AND DATA (MAD) LANDSCAPE 2021



Version 3.0 - November 2021

© Matt Turck (@mattturck), John Wu (@john_d_wu) & FirstMark (@firstmarkcap)

mattturck.com/data2021

<https://mattturck.com/data2021/>

FIRSTMARK
EARLY STAGE VENTURE CAPITAL

Data-related job opportunities

(Big) Data...

- Analyst
- Architect
- Engineer
- Scientist


Data-related job opportunities

The role that gained prominence with big data is the *data scientist*

- Data Scientist: The Sexiest Job of the 21st Century [Harvard Business Review 2013]
- Data scientist? A guide to 2015's hottest profession [Mashable 2015]
- "It's official – data scientist is the best job in America" [Forbes, 2016]



Data-related job opportunities



Data-related job opportunities

Data Architect



Develops data architecture to effectively capture, integrate, organize, centralize and maintain data. Core responsibilities include:

- ✓ Data Warehousing Solutions
- ✓ Extraction, Transformation and Load (ETL)
- ✓ Data Architecture Development
- ✓ Data Modeling

Data Analyst



Processes and interprets data to get actionable insights for a company. Responsibilities include:

- ✓ Data Collection and Processing
- ✓ Programming
- ✓ Machine Learning
- ✓ Data Munging
- ✓ Data Visualization
- ✓ Applying Statistical Analysis

Data Engineer



Develop, test and maintain data architectures to keep data accessible and ready for analysis. Key tasks are:

- ✓ Extraction Transformation and Load (ETL)
- ✓ Installing Data Warehousing Solutions
- ✓ Data Modeling
- ✓ Data Architecture Construction and Development
- ✓ Database Architecture Testing

Data Scientist




Data analysis once data volume and velocity reaches a level requiring sophisticated technical skills. Core tasks are:

- ✓ Data Cleansing and Processing
- ✓ Predictive Modeling
- ✓ Machine Learning
- ✓ Identifying Questions
- ✓ Running Queries
- ✓ Applying Statistical Analysis
- ✓ Correlating Disparate Data
- ✓ Storytelling and Visualization

Not a universal taxonomy

- The boundary between roles is organizational and depends on the (scale of) the company

Demand for big data expertise



18 HIGHEST-PAYING TECH & IT JOBS FOR 2024

University of CINCINNATI ONLINE

OCCUPATION	EDUCATION NEEDED	SALARY
PRINCIPAL SOFTWARE ENGINEER	BACHELOR'S	\$207,000 – \$282,000
MACHINE LEARNING ENGINEER	BACHELOR'S	\$158,575 – \$254,250
ENGINEERING MANAGER	BACHELOR'S	\$173,000 – \$234,000
SOFTWARE ENGINEER (STAFF – SENIOR LEVELS)	BACHELOR'S	\$147,000 – \$226,000
DATA SCIENTIST	MASTER'S	\$154,000 – \$212,000
PRODUCT MANAGER (STAFF – SENIOR LEVELS)	BACHELOR'S	\$130,000 – \$208,000
TECHNICAL PROGRAM MANAGER	BACHELOR'S	\$147,000 – \$201,000
PRODUCT DESIGNER	BACHELOR'S	\$123,000 – \$188,000
SITE RELIABILITY ENGINEER	BACHELOR'S	\$120,000 – \$175,000
SENIOR DATA ANALYST	BACHELOR'S	\$125,000 – \$174,000
IT MANAGER	BACHELOR'S	\$169,510
COMPUTER AND INFORMATION RESEARCH SCIENTISTS	MASTER'S	\$145,080
SOFTWARE DEVELOPER	BACHELOR'S	\$130,160
COMPUTER NETWORK ARCHITECTS	BACHELOR'S	\$129,840
INFORMATION SECURITY ANALYSTS	BACHELOR'S	\$120,360
DATABASE ADMINISTRATORS AND ARCHITECTS	BACHELOR'S	\$117,450
COMPUTER SYSTEMS ANALYSTS	BACHELOR'S	\$103,800
COMPUTER PROGRAMMERS	BACHELOR'S	\$99,700

Academic opportunities

Master's Degree thesis

- Internal: work closely with us in the Business Intelligence Group on research-oriented projects
- External: internship on data-driven companies we collaborate with

Ph.D. program

- Develop strong skills in data management and analysis
- Work on innovative research projects with international collaborations
- It opens to academic career, and gives a know-how that is well-expendable in the industry

Conclusions

We live in the era of Big Data

- Availability of data across many domains
- Big opportunities to solve big problems
- Great demand for Big Data-skilled professionals

They can create value

- The challenge is how to manage and use them
- Methodological aspects are important
- A rapidly evolving area

